Aplicaciones específicas

Taller de Procesamiento de Señales

Agenda

1. Análisis Espectral
2. Modelo de Lenguaje
3. Sistemas de Recomendación

Transformada de Fourier

$$X\left(e^{j\omega}\right) = \sum_{t=-\infty}^{\infty} x_t \cdot e^{-j\omega t}$$

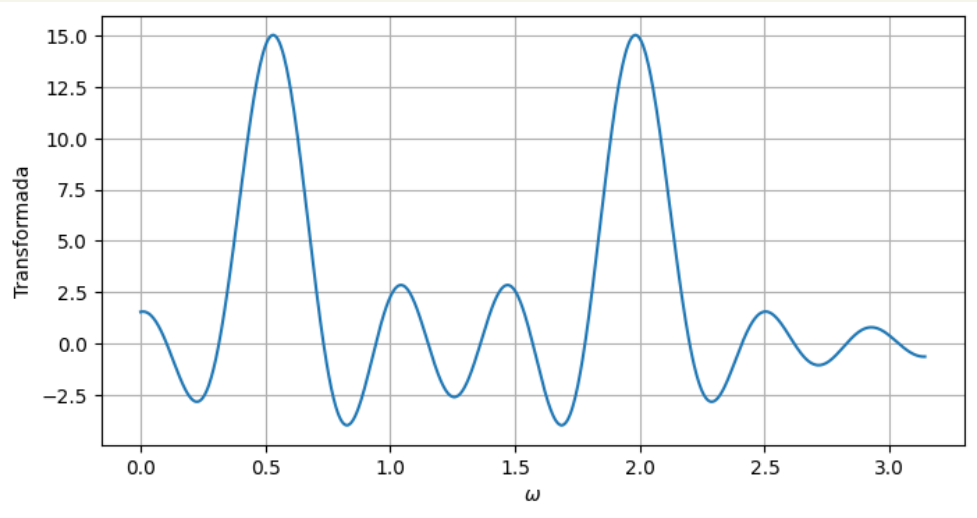
Algunas propiedades de la transformada de Fourier

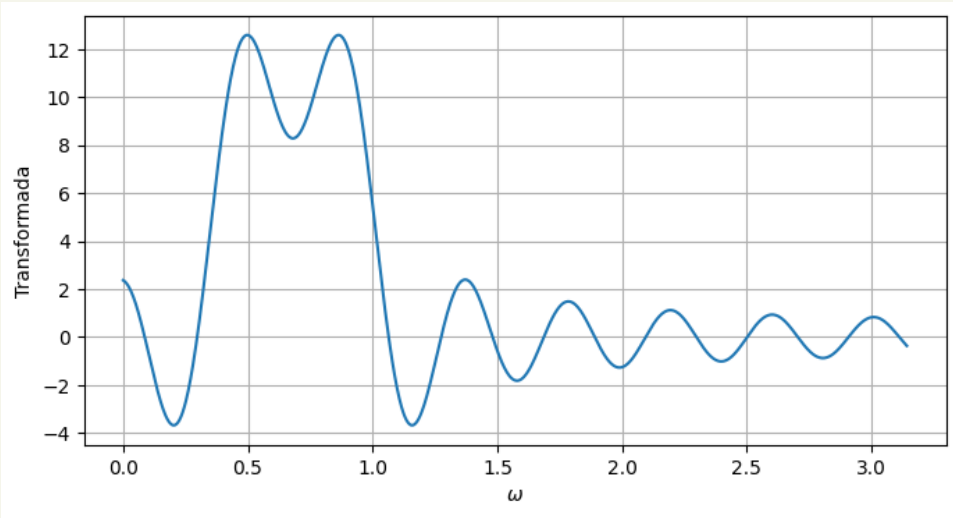
1. Periodicidad: $X\left(e^{j\omega}\right) = X\left(e^{j(\omega+2\pi\cdot k)}\right)$ para todo $k \in \mathbb{Z}$.
2. Reversibilidad: $x_t = \frac{1}{2\pi}\int_{-\pi}^{\pi} X\left(e^{j\omega}\right) e^{j\omega t} d\omega$.
3. Parseval (conservación de la energía): $\sum_{t=-\infty}^{\infty} |x_t|^2 = \frac{1}{2\pi}\int_{-\pi}^{\pi} |X\left(e^{j\omega}\right)|^2 d\omega$.
4. Desplazamiento temporal: $\mathcal{F}\left[\{x_{t-t_0}\}_{t=-\infty}^{\infty}\right] = e^{-j\omega t_0} X\left(e^{j\omega}\right)$.
5. Simetría conjugada: Si x_t es una señal real entonces $\mathrm{Re}(X(e^{j\omega})) = \mathrm{Re}(X(e^{-j\omega}))$ y $\mathrm{Im}(X(e^{j\omega})) = -\mathrm{Im}(X(e^{-j\omega}))$
6. Multiplicación: $\mathcal{F}\left[\{x_t \cdot y_t\}_{t=-\infty}^{\infty}\right] = \frac{1}{2\pi}\int_{-\pi}^{\pi} X\left(e^{j\nu}\right) Y\left(e^{j(\omega-\nu)}\right) d\nu$

Ventaneo: Las señales digitales no son infinitas

Spectral Leakage

La necesidad de truncar o **ventanear** la señal temporal, implica convolucionar en frecuencia (entre los espectros de la señal infinita y la ventana). Esto quiere decir que el espectro se va a haber deformado por el truncamiento de la señal (*spectral leakage*), pudiendo perder información relevante durante la operación.





Ventaneo: Comparación de ventanas

Ventana	**Ancho del lóbulo principal**	**Atenuación del lóbulo secundario**	**Decaimiento de los lóbulos laterales**
Rectangular	$\sim \frac{4\pi}{L}$	~ -13 dB	~ 6 dB/octava
Bartlett	$\sim \frac{8\pi}{L}$	~ -25 dB	~ 12 dB/octava
Hann	$\sim \frac{8\pi}{L}$	~ -31 dB	~ 18 dB/octava
Hamming	$\sim \frac{8\pi}{L}$	~ -43 dB	~ 6 dB/octava
Blackman	$\sim \frac{12\pi}{L}$	~ -58 dB	~ 18 dB/octava

Transformada Discreta de Fourier (DFT)

$$X[k] = X\left(e^{j\frac{2\pi k}{N}}\right) = \sum_{t=0}^{N-1} x_t e^{-j\frac{2\pi kt}{N}}$$

Zero-padding: Pro

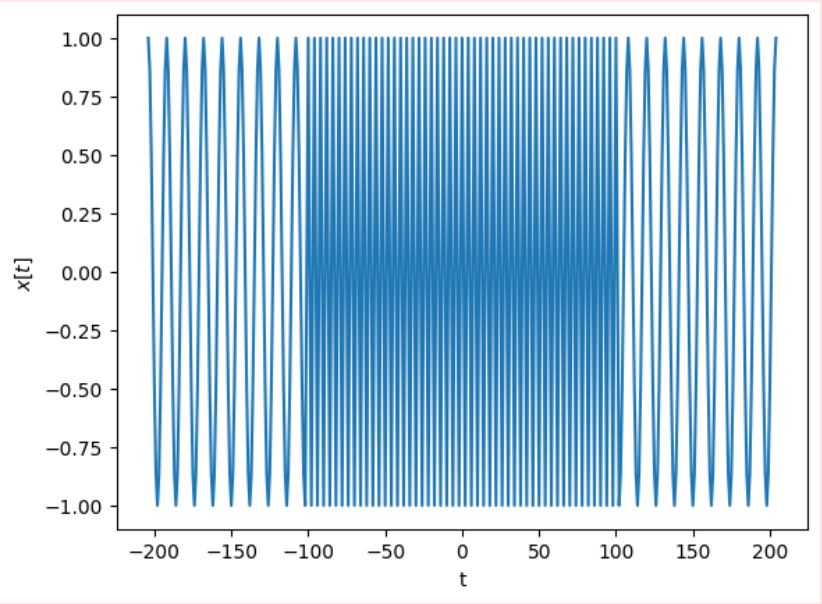
La cantidad de frecuencias resultante N no puede ser menor que la cantidad de puntos de la ventana L, porque de otra manera se perdería información (no sería una operación inversible). Pero nada impide que sea mayor, lo cuál equivale a completar con ceros la señal x_t (**zero padding**).

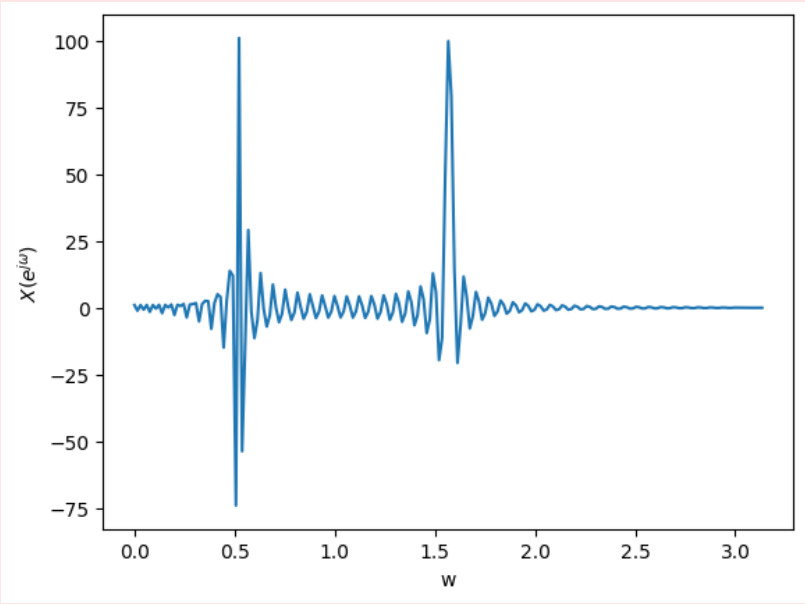
Zero-padding: Contra

Esta operación no aumenta la resoulción espectral de la señal (sigue determinada por ancho del lóbulo principal). Obtener una grilla más densa de frecuencias, si bien suaviza visualmente el espectro, obtiene más información sobre la ventana que sobre la señal en cuestión.

Transformada de Fourier de Corto Tiempo (STFT)

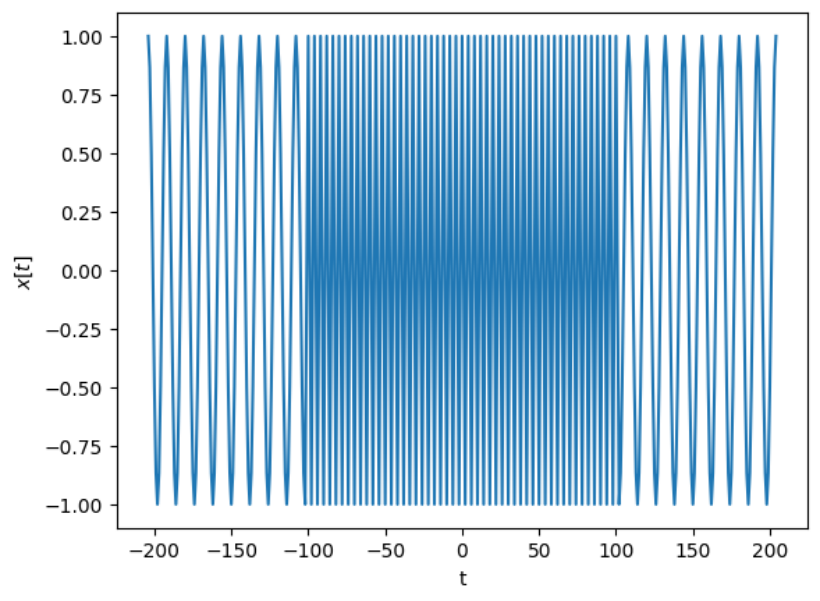
Problema: Señales no estacionarias

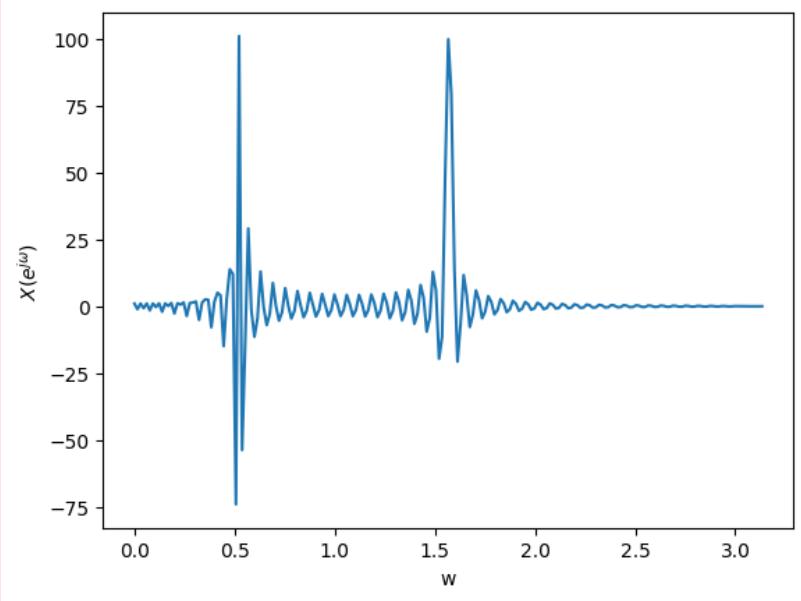




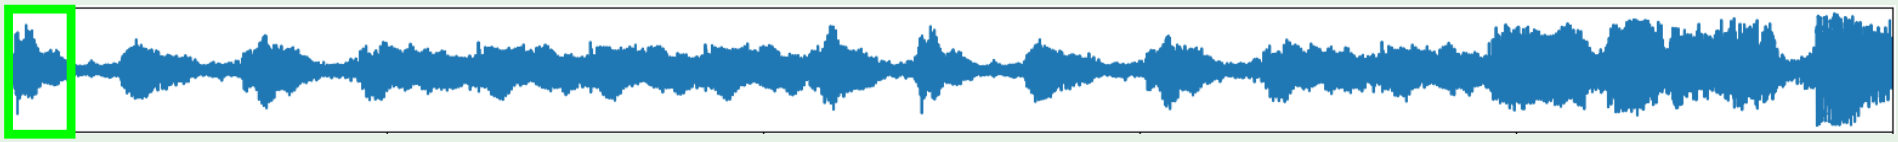
Transformada de Fourier de Corto Tiempo (STFT)

Problema: Señales no estacionarias





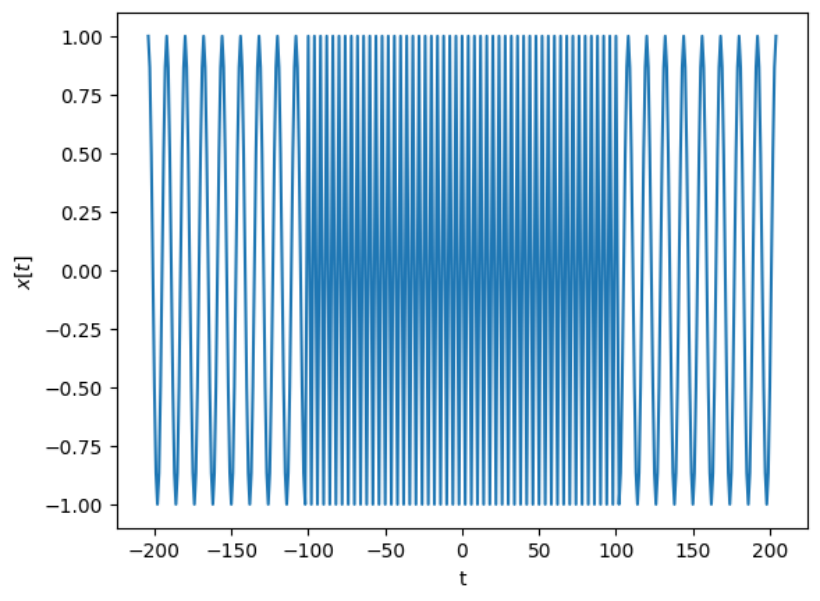
Solución: STFT

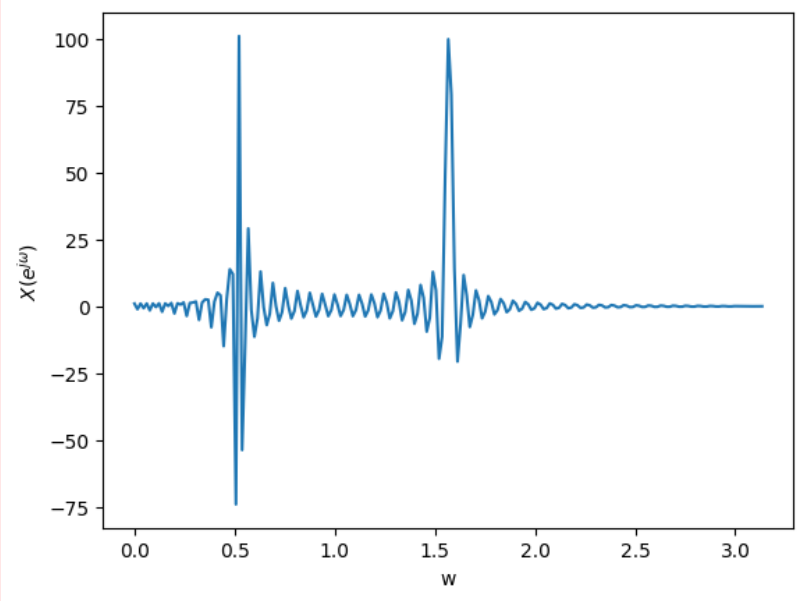


$$X(t,\omega) = \mathrm{DFT}\left(x[t]w[t]\right)$$

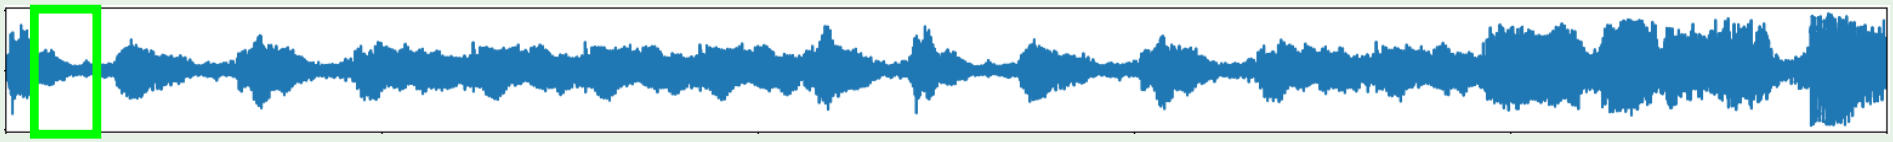
Transformada de Fourier de Corto Tiempo (STFT)

Problema: Señales no estacionarias





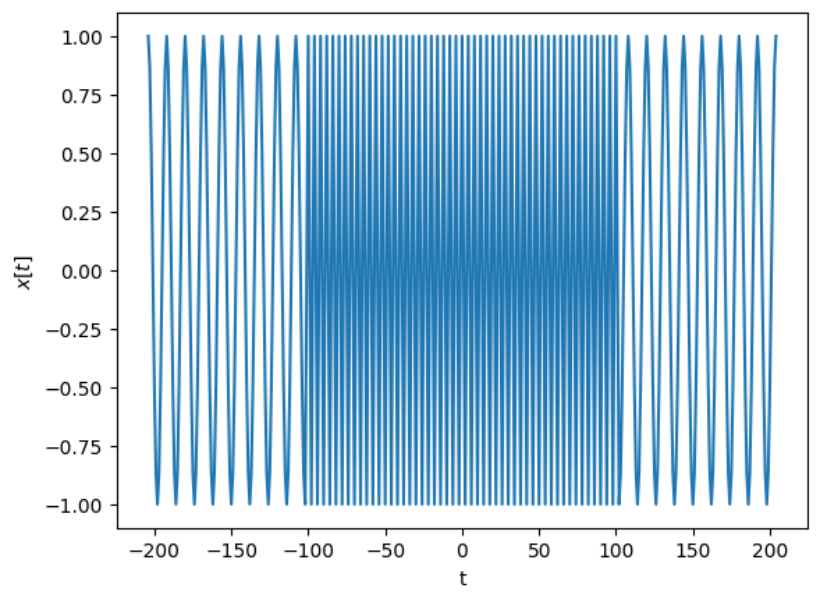
Solución: STFT

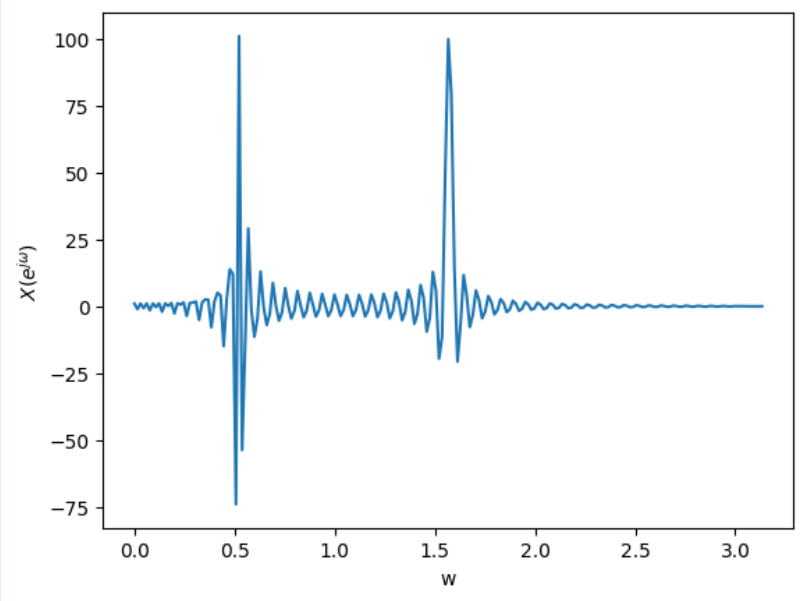


$$X(t,\omega) = \mathrm{DFT}\left(x[t]w[t]\right)$$

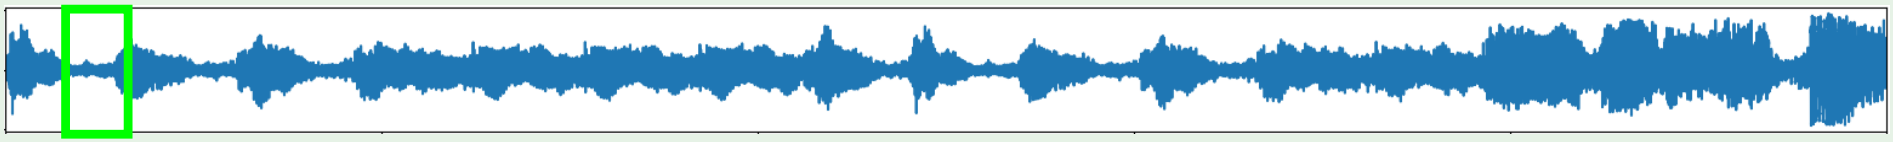
Transformada de Fourier de Corto Tiempo (STFT)

Problema: Señales no estacionarias





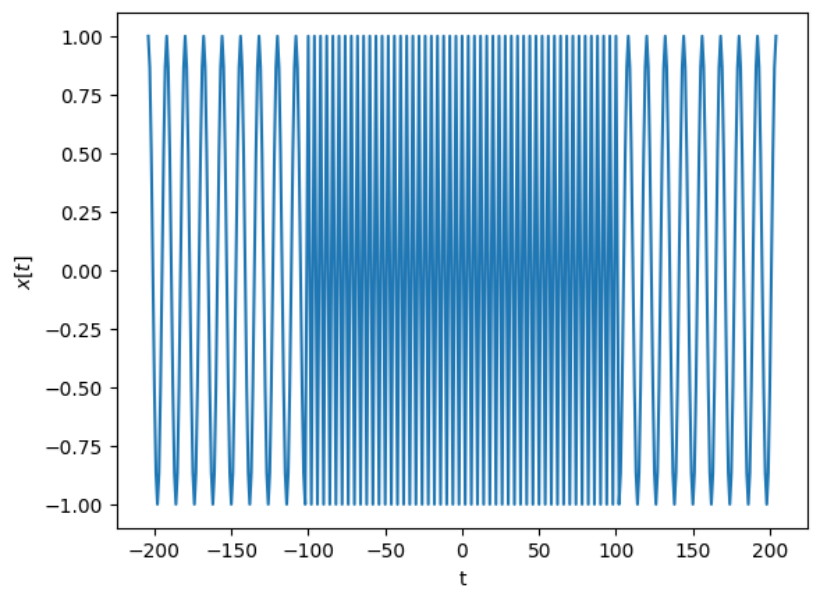
Solución: STFT

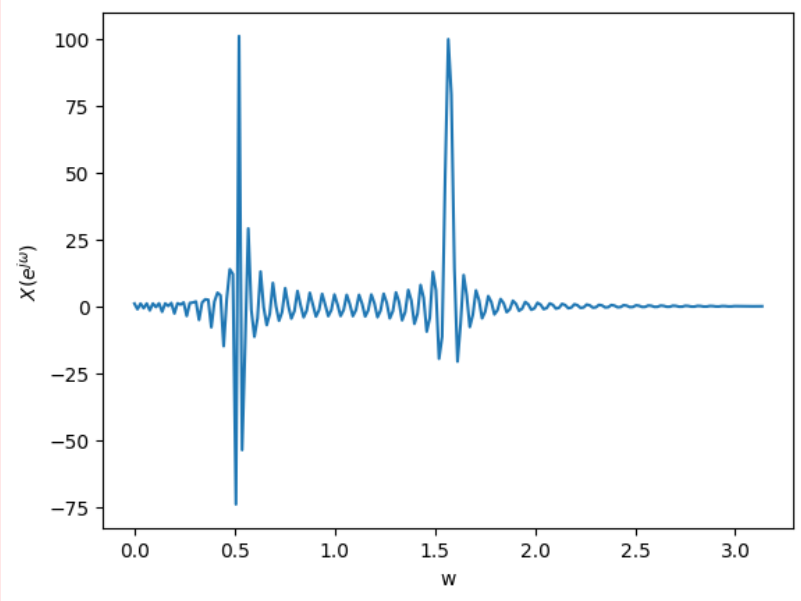


$$X(t,\omega) = \mathrm{DFT}\left(x[t]w[t]\right)$$

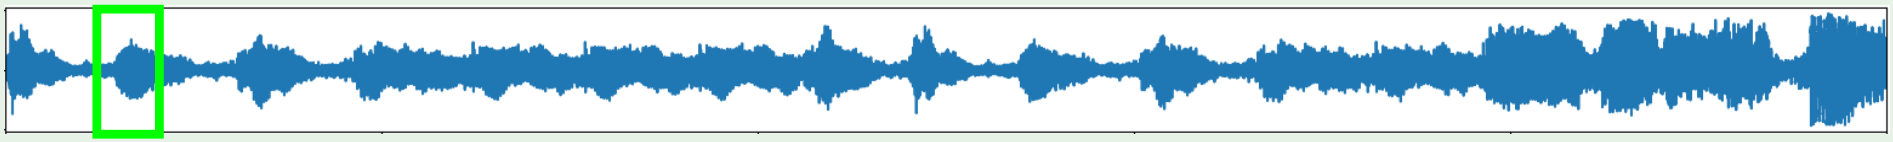
Transformada de Fourier de Corto Tiempo (STFT)

Problema: Señales no estacionarias





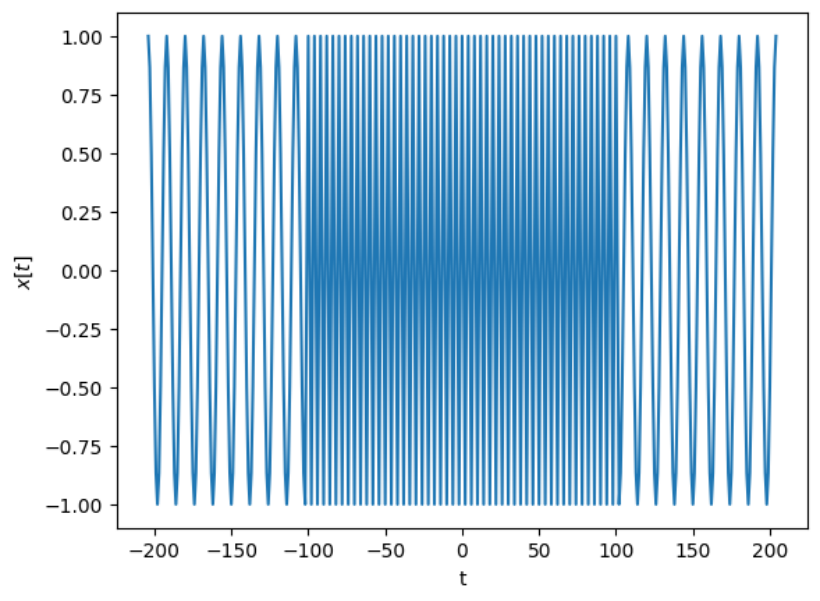
Solución: STFT

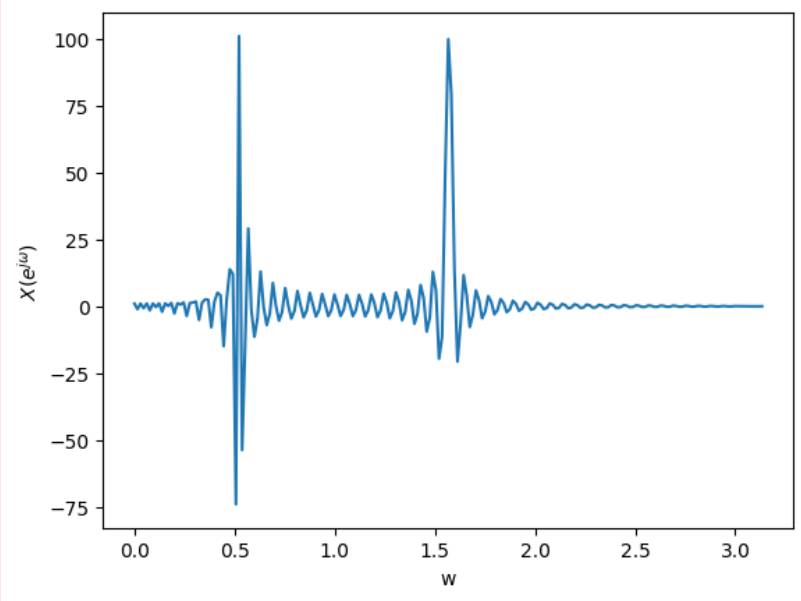


$$X(t,\omega) = \mathrm{DFT}\left(x[t]w[t]\right)$$

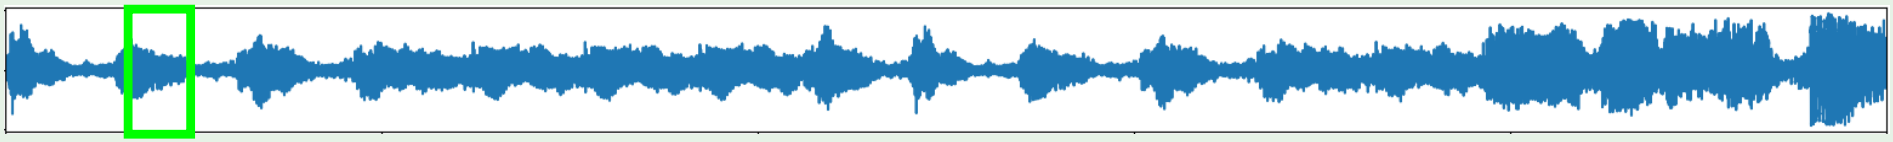
Transformada de Fourier de Corto Tiempo (STFT)

Problema: Señales no estacionarias





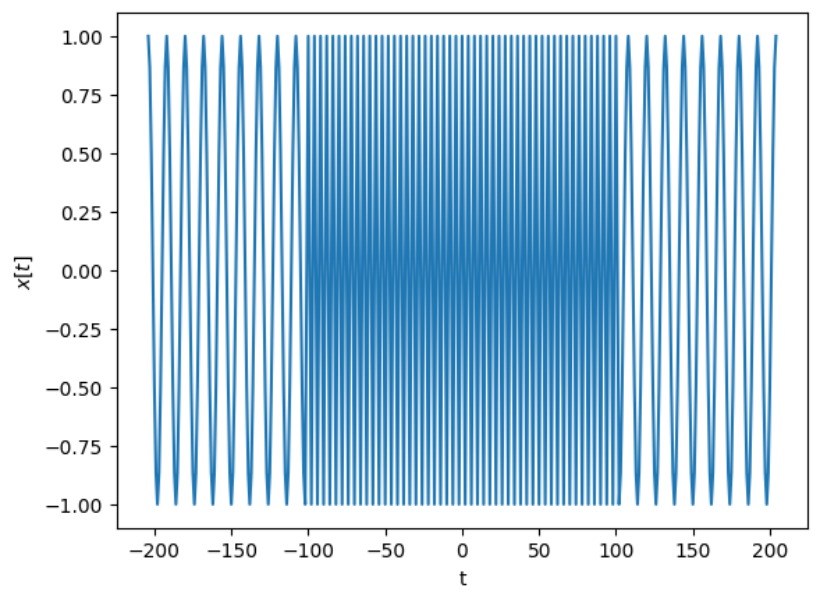
Solución: STFT

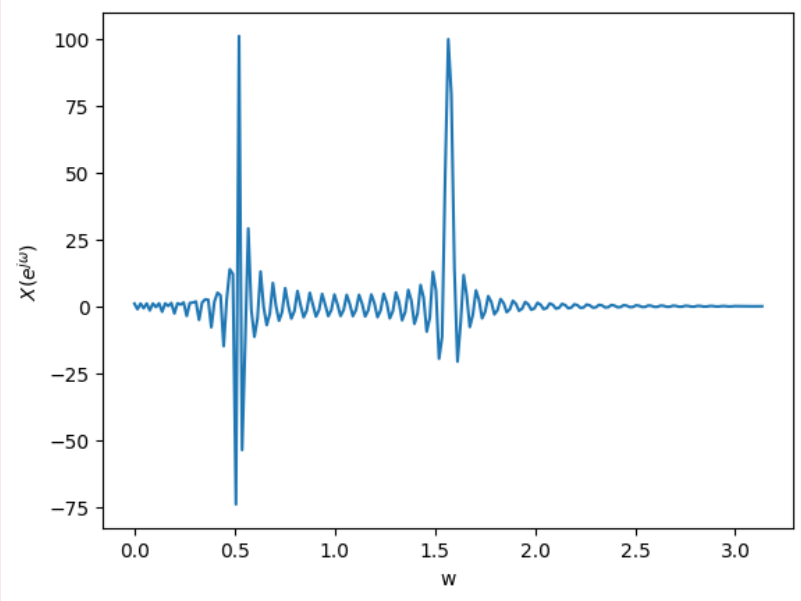


$$X(t,\omega) = \mathrm{DFT}\left(x[t]w[t]\right)$$

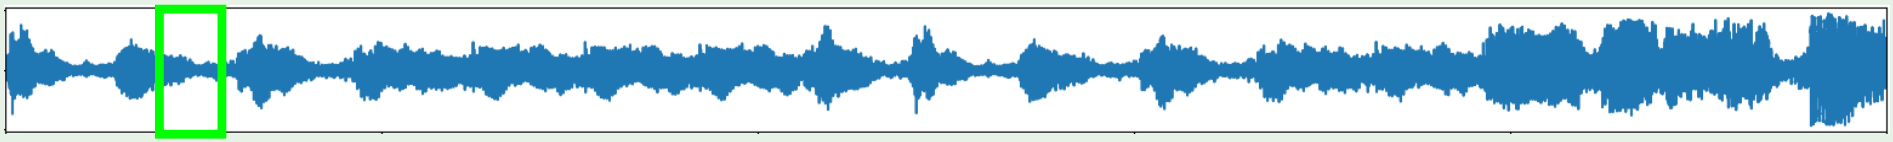
Transformada de Fourier de Corto Tiempo (STFT)

Problema: Señales no estacionarias



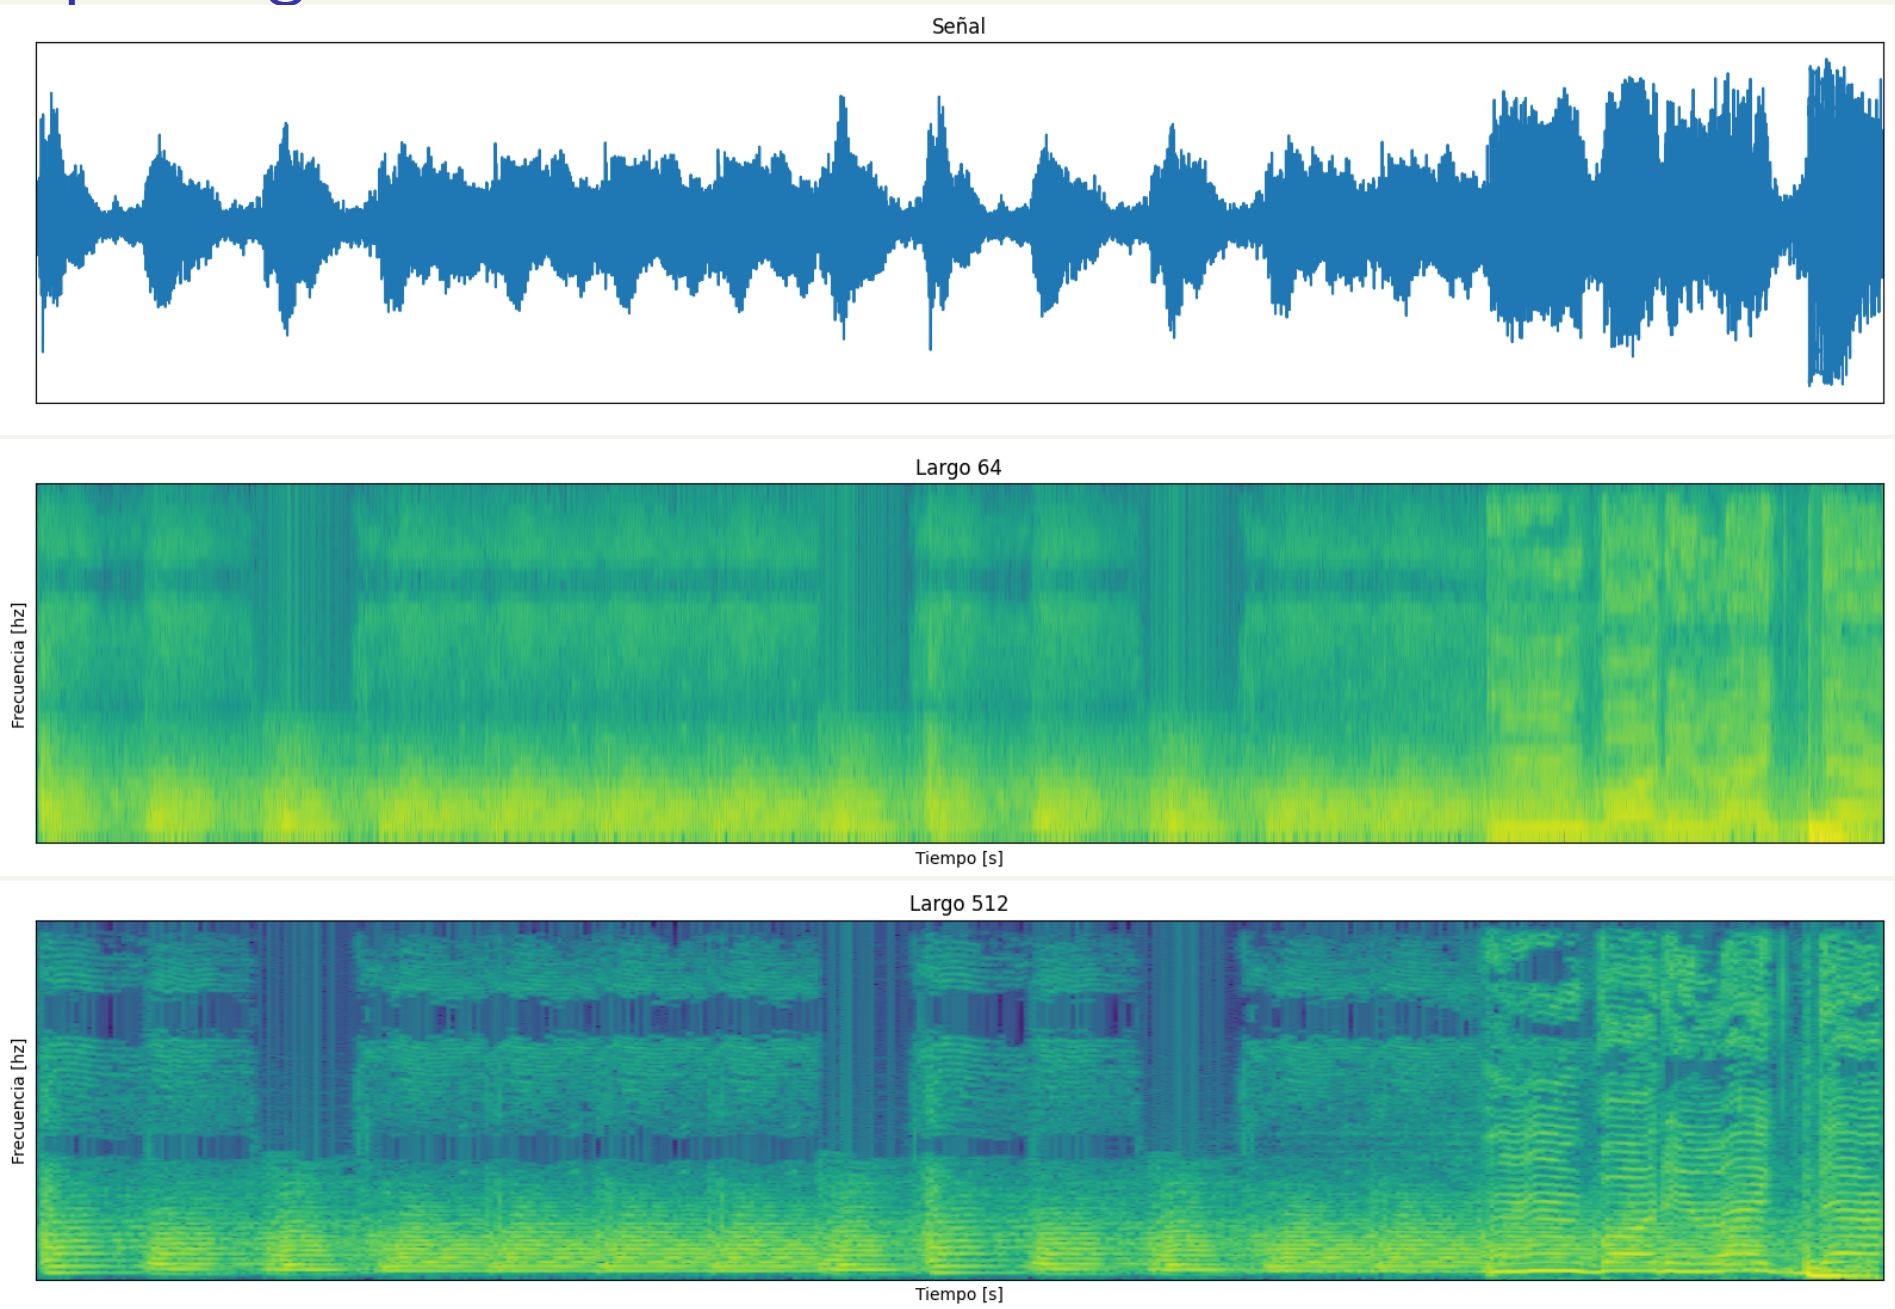


Solución: STFT



$$X(t,\omega) = \mathrm{DFT}\left(x[t]w[t]\right)$$

Espectrograma: Gráfico del módulo de la STFT



Outline

1 Análisis Espectral

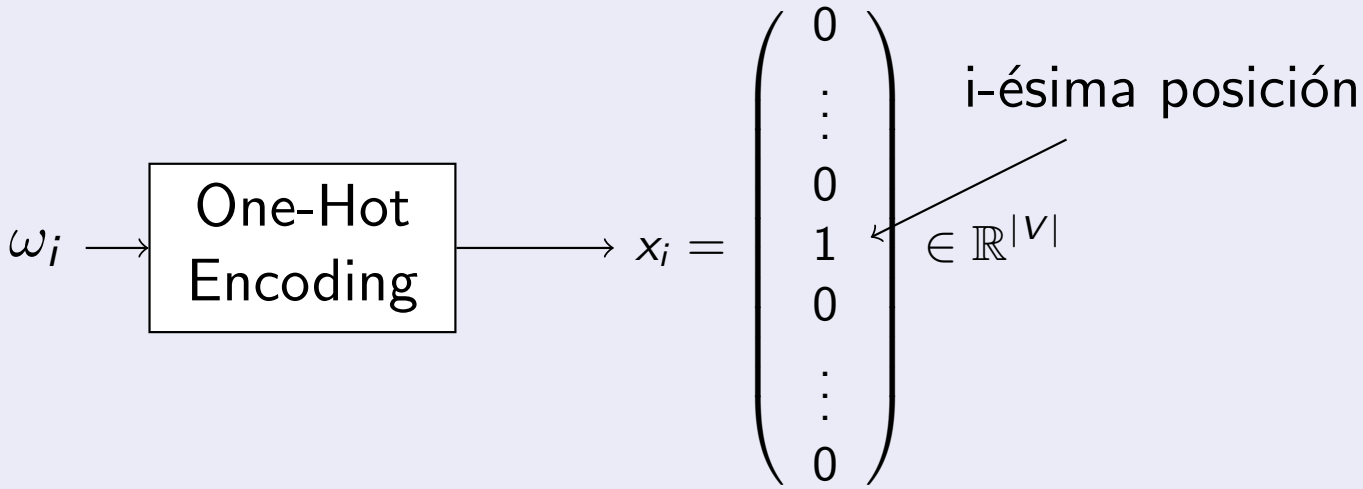
2 Modelo de Lenguaje

3 Sistemas de Recomendación

¿Como convertir un texto en un vector?

Word2vec

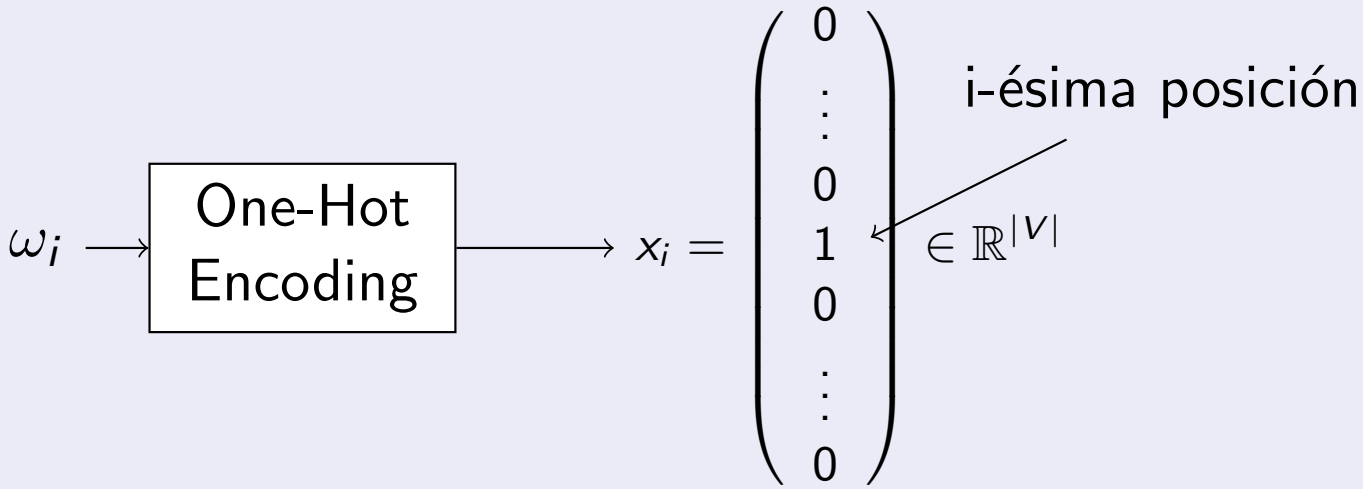
El método más sencillo para convertir una palabra en un vector es el *One-hot Encoding*. Dado un vocabulario $V = \{\omega_1, \cdots, \omega_{|V|}\}$, se puede convertir cada palabra en un vector *one-hot*.



¿Como convertir un texto en un vector?

Word2vec

El método más sencillo para convertir una palabra en un vector es el *One-hot Encoding*. Dado un vocabulario $V = \{\omega_1, \cdots, \omega_{|V|}\}$, se puede convertir cada palabra en un vector *one-hot*.



Bolsa de palabras

La vectorización de un documento consiste en definir una función $f(x_1, \cdots, x_n)$. El método más simple es la *bolsa de palabras* $f(x_1, \cdots, x_n) = x_1 + \cdots + x_n$, donde cada coeficiente representa la cantidad de veces que apareció cada palabra del vocabulario.

Term Frequency - Inverse Document Frequency

Transformación tf-idf

Medida numérica que expresa cuán relevante es una palabra para un documento dentro de un dataset. El tf-idf para un término t de un documento d perteneciente a una colección de n documentos es $\text{tf-idf}(t, d) = \text{tf}(t, d) \cdot \text{idf}(t)$. El primer factor $\text{tf}(t, d) = \frac{\#(t \in d)}{\#(d)}$ es la cantidad de veces que aparece el término t en el documento d dividido la cantidad de términos que aparecen en el documento d. El segundo factor $\text{idf}(t) = 1 - \log\left(\frac{\text{df}(t)}{n}\right)$, donde $\text{df}(t)$ es la cantidad de documentos que poseen el término t en su interior.

Term Frequency - Inverse Document Frequency

Transformación tf-idf

Medida numérica que expresa cuán relevante es una palabra para un documento dentro de un dataset. El tf-idf para un término t de un documento d perteneciente a una colección de n documentos es $\text{tf-idf}(t, d) = \text{tf}(t, d) \cdot \text{idf}(t)$. El primer factor $\text{tf}(t, d) = \frac{\#(t \in d)}{\#(d)}$ es la cantidad de veces que aparece el término t en el documento d dividido la cantidad de términos que aparecen en el documento d. El segundo factor $\text{idf}(t) = 1 - \log\left(\frac{\text{df}(t)}{n}\right)$, donde $\text{df}(t)$ es la cantidad de documentos que poseen el término t en su interior.

Vectorización

Transformación tf-idf se puede utilizar para vectorizar: cada documento d se puede expresar como un vector cuya dimensión es el largo del vocabulario y se define como $v_d = [\text{tf-idf}(0, d), \cdots, \text{tf-idf}(|V|, d)]^T$.

Procesamiento del Lenguaje Natural

Vectorizaciones Sofisticadas

En la práctica suelen utilizarse representaciones pre-entrenadas (ejs. FastText, GloVe, BERT, GTE, etc).

Procesamiento del Lenguaje Natural

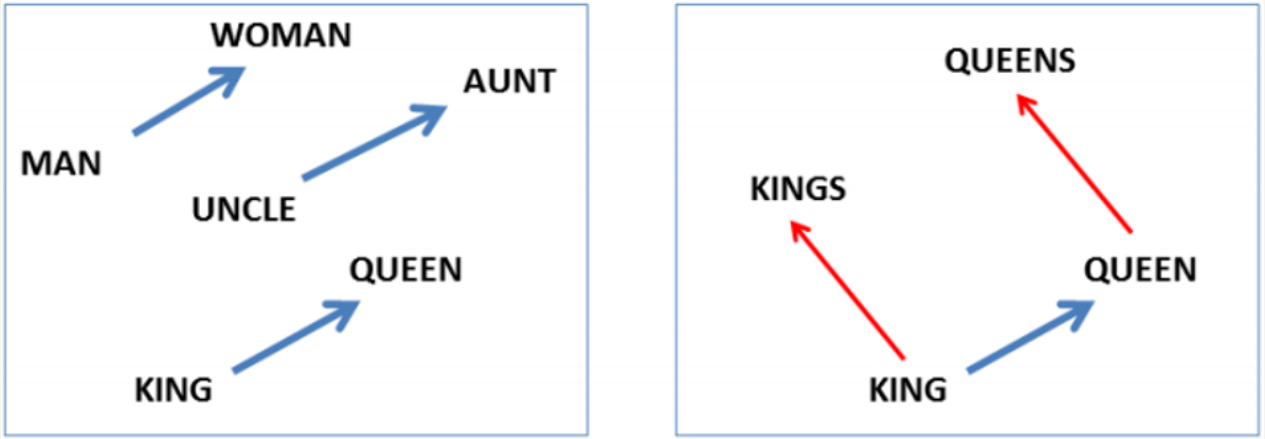
Vectorizaciones Sofisticadas

En la práctica suelen utilizarse representaciones pre-entrenadas (ejs. FastText, GloVe, BERT, GTE, etc).

Normalizaciones de NLP

- Eliminar caracteres raros e inusuales
- Convertir todo a minúsculas
- Eliminar palabras no informativas (stop words)
- Descartar las palabras poco observadas
- Descartar las palabras más comunes
- Lemmatization (significado)
- Stemming (quedarse con la raíz)

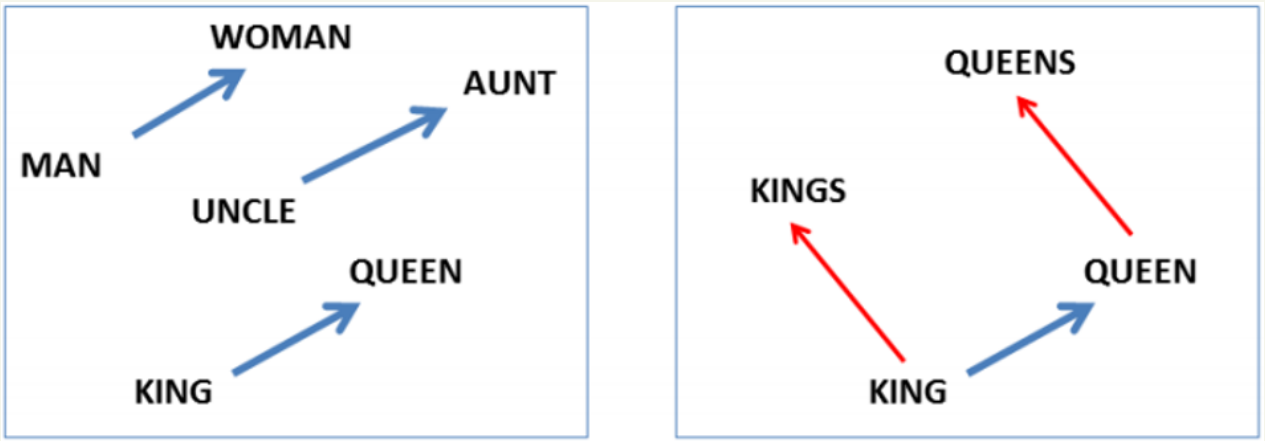
Word Vectors + PCA



(Mikolov et al., NAACL HLT, 2013)

vector(KINGS) - vector(KING) + vector(QUEEN) = vector(QUEENS)

Word Vectors + PCA



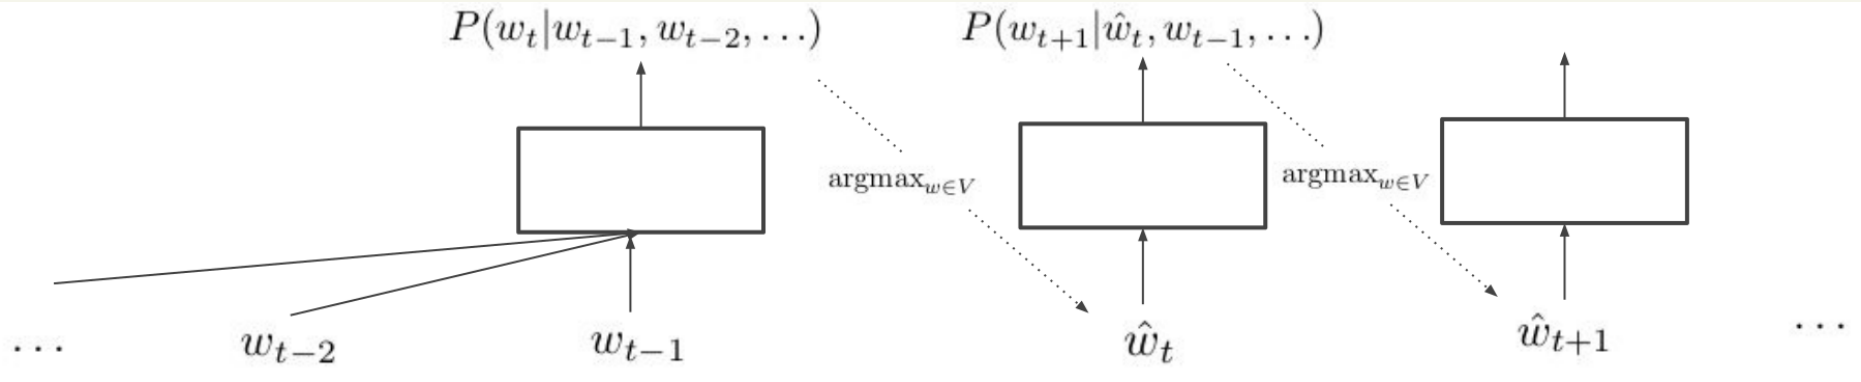
(Mikolov et al., NAACL HLT, 2013)

vector(KINGS) - vector(KING) + vector(QUEEN) = vector(QUEENS)

Similitud Coseno

El significado suele relacionarse con la dirección de los vectores, y por lo tanto, el ángulo entre vectores indica que tan similares son dos representaciones. La similitud coseno se define como el coseno del ángulo entre dos vectores $\mathbf{SC}(u, v) = \frac{u \cdot v}{\|u\|\|v\|}$.

Síntesis de texto



Outline

1 Análisis Espectral

2 Modelo de Lenguaje

3 Sistemas de Recomendación

Sistemas de Recomendación

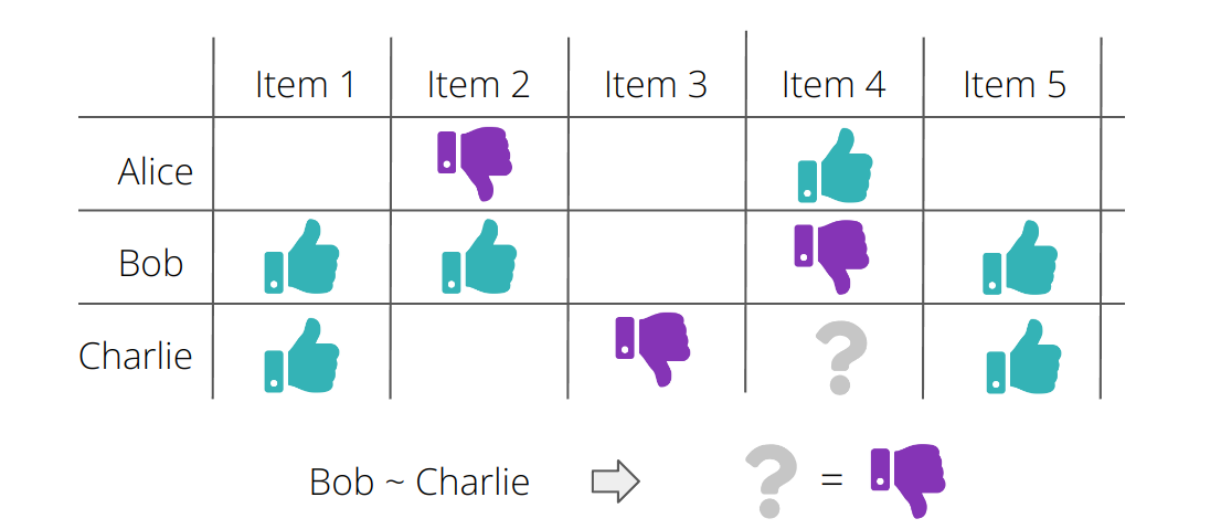


Algunas problemáticas asociadas

- *Cámara de eco*. Los algoritmos de recomendación tienden a juntar a personas con ideología similar, creando un ciclo de realimentación donde todos escuchan lo que ya creen, no se expone a puntos de vista diferentes, fomenta la radicalización y el dogmatismo.
- *Manipulaciones*. Los algoritmos no solo recomiendan según los gustos del usuario, sino que priorizan algunos contenidos por sobre otros. Pero no todos detallan los criterios utilizados para ellos.

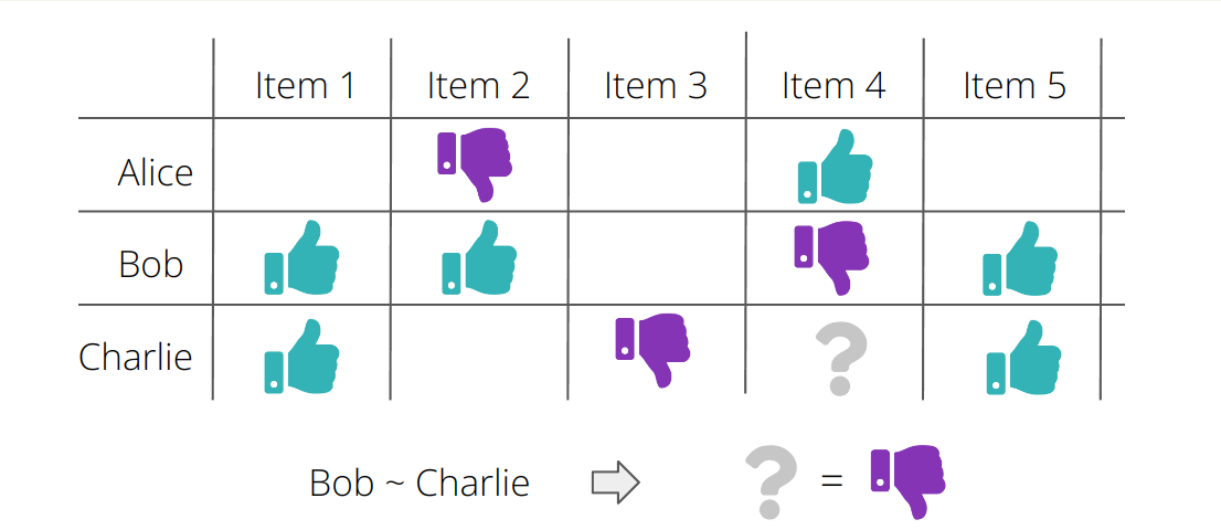
Filtro Colaborativo

Aprender por Colaboración



Filtro Colaborativo

Aprender por Colaboración



Entrenamiento

$$\min_{x,\theta} \frac{1}{2} \sum_{(i,j)\in\mathcal{R}} \left(\theta_j^T \cdot x_i - y_{i,j}\right)^2 + \frac{\lambda}{2} \left(\sum_{i=1}^{n_{\text{items}}} \|x_i\|^2 + \sum_{j=1}^{n_{\text{users}}} \|\theta_j\|^2 \right)$$

donde $\mathcal{R} = \{(i,j) : \ y_{i,j} \text{ tiene dato cargado}\}$, $y \in \mathbb{N}^{n_{\text{items}} \times n_{\text{users}}}$ contiene el dataset, $x \in \mathbb{R}^{n_{\text{items}} \times \nu}$ y $\theta \in \mathbb{R}^{n_{\text{users}} \times \nu}$ son los parámetros a entrenar; ν la dimensión del espacio latente y $\lambda \geq 0$ un hiperparámetro de regularización.

Filtro Colaborativo

Combinación convexa de factores durante la inferencia

Inferencia (Rating)

$$\hat{y}_{i,j} = p(\theta_j^T \cdot x_i) + (1 - p)\bar{y}_i$$

donde $\bar{y}_i$ es la calificación promedio del item i-ésimo (dentro de los datos cargados) y $0 \leq p \leq 1$ es un hiperparámetro que indica cuanto peso le damos al aprendizaje y cuanto al valor medio.

Filtro Colaborativo

Combinación convexa de factores durante la inferencia

Inferencia (Rating)

$$\hat{y}_{i,j} = p(\theta_j^T \cdot x_i) + (1 - p)\bar{y}_i$$

donde $\bar{y}_i$ es la calificación promedio del item i-ésimo (dentro de los datos cargados) y $0 \leq p \leq 1$ es un hiperparámetro que indica cuanto peso le damos al aprendizaje y cuanto al valor medio.



TECH / ELON MUSK

Yes, Elon Musk created a special system for showing you all his tweets first

/ After his Super Bowl tweet did worse numbers than President Biden's, Twitter's CEO ordered major changes to the algorithm.

theverge.com

by Zoë Schiffer and Casey Newton
Feb 14, 2023, 10:19 PM GMT-3

219 Comments (219 New)

Photo illustration by William Joel / The Verge, photo by Christian Marquardt / Getty Images